

Не совпадает со статьей на конкурс JMLC
Персонализированное ранжирование CrossSell-предложений
Выбор категорий по extra NPV
Проект для Junior ML Contest 2026

1 Бизнес-постановка

В проекте решается задача персонализации CrossSell-раздачи в крупной финтех-экосистеме. Пользователю показывается не весь каталог, а несколько допустимых предложений: сервисы, подписки, финансовые продукты или партнерские категории. Внутренние названия продуктов, точные значения ценности, схемы таблиц и рабочий код не раскрываются из-за NDA; в открытой версии используются обобщенные категории и синтетические данные. Бизнес-ценность – в росте утилизации продуктов и удержании пользователя в экосистеме: слотов немного, поэтому их важно отдавать тем предложениям, показ которых реально меняет поведение клиента.

Цель раздачи не клик и не сам факт выбора категории, а *утилизация*: пользователь должен начать пользоваться новым продуктом, счетом, сервисом или подпиской. Для пользователя i известны признаки x_i , допустимые категории K_i , число слотов m и нормированная ценность NPV_k . Стратегия выбирает ровно m категорий с учетом правил: категория должна быть доступна, а две категории одной продуктовой группы не должны попасть в одну раздачу.

Первоначально ценность категории оценивалась как вероятность утилизации, умноженная на NPV_k . Такая модель отвечает на вопрос: “что пользователь, вероятно, утилизует?” Однако клиент может иметь высокую вероятность утилизации и без показа. Поэтому для выбора категорий используется оценка дополнительной ценности, созданной именно воздействием:

$$extra_NPV_{ik} = NPV_k [\hat{p}(u_{ik} = 1 \mid x_i, k, z = 1) - \hat{p}(u_{ik} = 1 \mid x_i, k, z = 0)],$$

где $z = 1$ означает показ категории, а $z = 0$ означает отсутствие показа. Разность вероятностей является оценкой uplift, то есть дополнительного эффекта показа.

2 Данные и временные срезы

В контуре используются два типа данных. Табличная витрина для бустинга содержит строки пользователь–категория–период, признаки до подготовки раздачи, доступность, назначение z_{ik} , вероятность назначения и факт утилизации. Исторические события для трансформера задаются как последовательность записей с временем, типом действия, связанным объектом или категорией и дополнительными атрибутами. В нее попадают действия в приложении, взаимодействия с предложениями, транзакции, открытия и закрытия продуктов.

Для каждого целевого месяца используется только история, доступная на момент подготовки раздачи. Последовательность собирается с учетом производственного лага; обучение, валидация и итоговая проверка разделяются по времени, а не случайным перемешиванием строк. Это защищает признаки от утечки будущей утилизации.

3 Модели: бустинг, трансформер и гибрид

Исходные модели вероятности утилизации. В модельном контуре есть три уровня. Градиентный бустинг обучается на табличной витрине: агрегированных признаках пары пользователь–категория, частотах и давностях событий, истории взаимодействий, признаках категории и клиента. Он устойчив на табличных данных и дает сильную базовую точку сравнения.

Вторая – нейросетевая модель вероятности утилизации на базе BERT-like transformer encoder, близкая к two-tower архитектуре. Левая часть строит представление пользователя по последовательности событий: $h_i = E_{\theta}(events_i)$. Правая часть строит представление действия: для обычного прогноза это категория, а для uplift это пара “категория–показ”, то есть эмбединг действия содержит и категорию k , и индикатор z . Выходная MLP-голова оценивает вероятность утилизации:

$$\hat{p}_{ikz}^{tr} = \sigma(G_{\theta}[h_i, a_{kz}, h_i \odot a_{kz}, |h_i - a_{kz}|]).$$

Такой трансформер учитывает порядок и контекст событий. Например, недавняя последовательность “интерес к категории, действие в приложении, транзакция” несет иной сигнал, чем те же события, разнесенные на месяцы.

Uplift и гибридная модель. Оценка uplift опирается на случайную раздачу, которая проводится каждый месяц на части аудитории внутри допустимого набора категорий и сохраняет те же ограничения, что

и рабочая раздача. После запуска проверяются баланс предраздаточных признаков, доли назначений по категориям и группам, а также способность простой модели предсказывать факт показа по признакам до раздачи: $AUC(\hat{z}(x_i)) \approx 0.5$.

На логах такой раздачи обучается S-learner: модель получает признаки пары пользователь–категория и индикатор показа z , а таргетом остается факт утилизации. Гибридная модель не заменяет трансформер, а добавляет его прогноз как признак в итоговый бустинг вместе с табличными признаками и индикатором показа. Для одной пары пользователь–категория модель запускается при $z = 1$ и $z = 0$; разность прогнозов формирует uplift, а после умножения на NPV получается extra NPV:

$$\hat{\tau}_{ik} = \hat{p}_{ik,1}^{hyb} - \hat{p}_{ik,0}^{hyb}, \quad extra_NPV_{ik} = NPV_k \hat{\tau}_{ik}.$$

Если назначение хорошо предсказывается по предраздаточным признакам, значит в логах осталась скрытая селекция и причинная интерпретация uplift ненадежна.

Выбор категорий. На применении модель скорирует пары пользователь–категория, после чего к результатам применяется преселект доступных категорий. Набор заполняется жадно: на каждом шаге выбирается категория с максимальной оценкой среди доступных, после чего исключаются категории, нарушающие правила сочетаний. Сравниваются случайный выбор, ранжирование по NPV, ранжирование по ожидаемой ценности $\hat{p}(u_{ik} = 1) \cdot NPV_k$ и ранжирование по extra NPV.

4 Проверка на исторических данных и открытая версия

Стратегия выбора категорий по extra NPV проверяется на логах случайной раздачи. Если выбранная новой стратегией категория совпала с фактически показанной, ее вклад взвешивается через вероятность показа. Для более строгой проверки также считается оценка всего набора A_i , где $p_i(A_i)$ означает вероятность случайного назначения именно этого набора при тех же ограничениях. IPS-оценка ожидаемой ценности стратегии π имеет вид:

$$\hat{V}_{IPS}(\pi) = \frac{1}{N} \sum_{i=1}^N \frac{y_i \mathbf{1}\{A_i = \pi(x_i)\}}{p_i(A_i)}.$$

Здесь y_i обозначает наблюдаемый результат: утилизацию или нормированную ценность. Если раздача строится последовательно по слотам, вероятность набора восстанавливается из условных вероятностей назначений. Дополнительно считаются нормированная IPS-оценка, эффективный размер выборки, число совпадений, бутстреп-интервалы и диагностика uplift.

Публичный репозиторий не содержит рабочих данных, точных NPV и внутреннего кода. В нем реализована синтетическая реконструкция: генератор пользователей, категорий, событий, случайной раздачи и неоднородного эффекта показа. В demo и notebook сравниваются случайный выбор, ранжирование по NPV, по $\hat{p}(u_{ik} = 1) \cdot NPV_k$, по extra NPV и выбор по истинному эффекту. В закрытом контуре последовательностный подход и extra NPV-ранжирование дают лучший порядок качества; открытая синтетика воспроизводит эту логику без раскрытия метрик. Выбор по истинному эффекту возможен только в синтетике и служит проверкой, что модель учится выбирать добавочную ценность, а не общую активность пользователя. Открытая версия снабжена облегченной, но реально запускаемой инженерной обвязкой: модели написаны на numpy/pandas без тяжелых библиотек, сборка упакована в Docker, CI на GitHub Actions прогоняет тесты при каждом изменении, а пример Airflow DAG воспроизводит ту же последовательность шагов поверх синтетики. Бустинг и трансформер в открытой версии — намеренно упрощенные mini-реализации: они демонстрируют принцип extra NPV, а не рабочие метрики. Главная метрика оценки — добавленная ценность (инкремент от показа), а не наблюдаемая утилизация; по ней синтетический потолок задает верхнюю границу, а лучшая обучаемая стратегия опирается на последовательностную модель.

5 Инженерная часть

Рабочее решение оформляется как параметризованный ML-пайплайн. Код пайплайна хранится в GitLab: отдельные Python-модули отвечают за загрузку данных, подготовку признаков, модели, оценку продуктов и формирование назначений. В CI код проходит проверки, после чего собирается Docker-образ для запуска расчета. Airflow оркестрирует сбор данных, расчет прогнозов для всех пар пользователь–категория и применение продуктовых правил.

ML-пайплайн




Рис. 1: Инженерный контур расчета: код версионизируется в GitLab, CI проверяет изменения и собирает Docker-образ, а Airflow запускает сбор данных, скоринг всех пар пользователь-категория и выбор итогового набора.

6 Применение ИИ

Для автоматизации регулярной аналитической работы я создал сценарий ИИ-аналитика. Он работает с результатами запусков, логами и ML-дашбордом: ищет аномалии в метриках по моделям и продуктовым группам, формулирует гипотезы, готовит SQL-срезы, черновики задач и отчеты. Перед созданием задачи или отчета агент запрашивает подтверждение.

МСР-коннекторы и корпоративные доступы я не разрабатывал как отдельную платформу: моя роль состояла в интеграции доступных ИИ-инструментов в рабочий процесс и настройке правил их безопасного применения. Аналитический контур проще автоматизировать первым: SQL-запросы и отчеты легче проверить, а цена ошибки ниже. Поэтому на аналитике обкатываются подходы, которые затем можно осторожно переносить в ML-разработку.

В ML-контуре уровень автоматизации ниже: изменение модели или стратегии ранжирования требует экспериментов, причинной проверки, контроля утечек и учета продуктовых ограничений. Здесь ИИ используется как набор специализированных навыков: проверка данных и временных срезов, генерация гипотез, ревью uplift-оценки, помощь с кодом и анализ ошибок в GitLab/CI. Отдельный навык проверяет техническую постановку, причинную интерпретацию, воспроизводимость и соблюдение NDA.

7 Личный вклад и развитие

Мой вклад включает формализацию CrossSell-раздачи как задачи ранжирования с ограничениями, разработку бустинга и трансформерной модели, построение гибридной схемы со стекингом и внедрение extra NPV в качестве целевой метрики для приоритизации категорий. Отдельно я создал открытую синтетическую реконструкцию с учетом NDA. Продуктовые правила, бизнес-метрики и запуск раздач обсуждаются совместно с менеджерами и аналитиками; модельная постановка и эксперименты находятся в моей зоне ответственности.

Следующий этап развития – для части продуктов перейти от выбора категории к совместному выбору категории и ставки скидки. Для каждой пары пользователь-категория можно сравнивать несколько уровней скидки и выбирать вариант, который максимизирует extra NPV за вычетом ожидаемой стоимости с учетом бюджетного ограничения. Такой переход сохраняет правила доступности, разнообразия набора и проверку качества на случайных логах. Отдельное направление развития – интеграция других uplift-моделей (R-learner, DR-learner) для более надежной оценки эффекта показа.