

Персонализированное ранжирование CrossSell-предложений

Андрей Иванов
Data Scientist

Бизнес-задача: персональная CrossSell-раздача

Цель — привлекать и удерживать клиентов в экосистеме: подключить или возобновить продукт при ограниченном бюджете скидок.

Что показываем

Не весь каталог, а несколько допустимых CrossSell-предложений — сервисы, подписки, финансовые и партнёрские категории. Слотов мало, бюджет скидок ограничен.

Как выбираем

Скорим все пары клиент-продукт (вероятность утилизации и uplift) и берём top-3 по бизнес-правилу — без повторов group_id. Полный пайплайн — на слайде «Инженерия».

Почему response-скоринг недостаточен

Высокая вероятность утилизации не означает, что показ создал ценность.

Response ranking

Сортируем по:
 $p(\text{utilization}) \times \text{NPV}$

Риск: слоты уходят клиентам, которые и так бы утилизировали продукт.



Extra NPV ranking

Сортируем по:
 $\text{NPV} \times (p_1 - p_0)$

Фокус: где показ категории реально меняет поведение клиента.

Данные и временные срезы

Табличная витрина

строка клиент-продукт-период
агрегаты, доступность, NPV
история взаимодействий

Исторические события

клики, транзакции, действия
показы и активации
открытия/закрытия продуктов


Обучение, валидация и тест разделены по времени, а не случайным перемешиванием.



Главная проверка: в последовательностях нет будущих событий относительно даты подготовки раздачи.

Модели: бустинг, трансформер и гибрид


Табличная модель ловит агрегаты, трансформер — порядок событий, гибрид объединяет оба сигнала.



Uplift считается S-learner-логикой: разность прогнозов при $z=1$ и $z=0$ дает uplift; $\text{extra NPV} = \text{NPV} \times \text{uplift}$.

Uplift-моделирование: эффект показа, а не склонность

Случайная раздача и S-learner позволяют оценить добавочный эффект показа, отделив его от базовой склонности клиента.



Проверяем, что показ случаен: по признакам до раздачи его не угадать — ROC AUC ≈ 0.5 .

Оцениваем стратегию выбора, а не только модель

Нас интересует ценность итоговой раздачи top-3, а не только AUC классификатора.

IPS / SNIPS

оценка по randomized logs

поправка на вероятность назначения

ESS + bootstrap

надежность оценки

overlap и доверительные интервалы

ИСТИННЫЙ эффект

только в синтетике

известны реальные p_1 и p_0

Классификатор предсказывает склонность к утилизации. Ценность стратегии меряем по добавочному эффекту (true extra NPV) — наблюдаемая утилизация (SNIPS) для этого вторична.

Результаты: transformer — лучший среди моделей


Главная метрика — true extra NPV: в синтетике она показывает истинный инкремент от показа.



Что такое потолок?

Недоступная в реальности стратегия, которая в синтетике знает истинные p_0 и p_1 . Нужна как верхняя граница качества.

ML-пайплайн: от данных до итоговой раздачи



Airflow по расписанию запускает фиксированный код: собирает данные, скорит все пары клиент-продукт и применяет правила выбора.

Применение ИИ в работе и проекте

ИИ не заменяет ML-решения, а ускоряет ревью, аналитику, поиск ошибок и подготовку артефактов.

Навыки для ML-разработки

data workflow — временные срезы, event history, утечки
code workflow — notebook, тесты, воспроизводимость
model improvement — идеи и диагностики
uplift workflow — randomized logs, extra NPV, IPS
JMLC council — ML / causal / MLOps / NDA ревью

ИИ-аналитик в регулярной работе

работает с результатами запусков и ML-дашбордом
ищет аномалии и зоны роста
готовит SQL-срезы, задачи и отчеты
перед действиями спрашивает подтверждение
по итогам фиксирует отчет в Confluence/Jira

Пример: ИИ-ревью прошло репозиторий по 5 линзам и нашло незакрытую overlap-проверку — я её доделал и перепроверил. Готовые ИИ-инструменты встраиваю в рабочий процесс и задаю правила их безопасного применения.

Итог и планы

Что сделано

- Поставил задачу персонального выбора CrossSell-категорий как ранжирование с ограничениями
- Разработал и сравнил бустинг и BERT-like transformer encoder, объединил их в гибрид со stacking
- Перешёл от response-скоринга к uplift-моделированию: добавочный эффект показа (extra NPV) с проверкой на randomized logs
- Организовал сборку и регулярный запуск через GitLab, CI и Airflow
- Для JMLC собрал синтетический репозиторий, имитирующий рабочую сборку без раскрытия NDA

Дальнейшее развитие

- совместный выбор «категория + ставка скидки» под бюджет
- интеграция других uplift-моделей: R-learner, DR-learner

Appendix: формулы extra NPV и IPS

extra NPV

$$\text{extraNPV}_{ik} = NPV_k \cdot (\hat{p}_{1,ik} - \hat{p}_{0,ik})$$

$$\hat{p}_{1,ik} = \hat{P}(u_{ik} = 1 \mid x_i, k, z = 1), \quad \hat{p}_{0,ik} = \hat{P}(u_{ik} = 1 \mid x_i, k, z = 0)$$

z=1 — категория показана, z=0 — не показана.

IPS / SNIPS

$$\hat{V}_{\text{IPS}}(\pi) = \frac{1}{n} \sum_{i=1}^n w_i y_i, \quad w_i = \frac{\mathbf{1}\{a_i = \pi(x_i)\}}{p_i(a_i)}$$


$$\hat{V}_{\text{SNIPS}}(\pi) = \frac{\sum_{i=1}^n w_i y_i}{\sum_{i=1}^n w_i}$$

- a_i — назначенная категория или набор
- $p_i(a_i)$ — вероятность назначения в random logs

Ключевая интерпретация

extra NPV ранжирует не по общей склонности клиента, а по добавочному эффекту показа. IPS/SNIPS нужны, чтобы сравнивать стратегию выбора top-3 на логах случайной раздачи.


Appendix: two-tower-like transformer ranking



Event sequence -> user_embedding; category + z -> action_embedding; вместе они дают score пары клиент-категория.

Appendix: синтетический репозиторий

NDA-safe версия воспроизводит ML-логику CrossSell: данные, модели, выбор top-3 и offline evaluation.



Как проверяется

- notebooks/demo.ipynb — основной интерактивный запуск для ревью
- run_experiment.py — тот же пайплайн из терминала с параметрами
- pytest + GitHub Actions — тесты, smoke run и сборка Docker-образа

Что показывает демо

- randomized logs и overlap-проверку: показ не должен угадываться по признакам
- сравнение random / NPV / response ranking / extra NPV / synthetic ceiling
- главную метрику: true extra NPV, то есть добавочную ценность показа

Не содержит рабочие данные, производственный код, точные NPV, внутренние названия и реальные схемы таблиц.